

Università degli Studi di Firenze  
Dipartimento di Ingegneria dell'Informazione (DINFO)

---

## Laboratorio di Automation

Project Work – A.A. 2025-26

---

# Localizzazione di sorgenti inquinanti marine: Metodo del Gradiente vs Reinforcement Learning (PPO)

Modulazione della velocità e doppia formazione di agenti

**Studente:** Mattia Manneschi

**Docenti:** Prof. Giorgio Battistelli, Prof. Nicola Forti

**Anno Acc.:** 2025-26

# Indice

|          |                                                                             |           |
|----------|-----------------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Introduzione</b>                                                         | <b>2</b>  |
| <b>2</b> | <b>Spawn Uniforme in <math>[d_{\min}, d_{\max}]</math></b>                  | <b>2</b>  |
| 2.1      | Definizione del disco di spawn . . . . .                                    | 2         |
| 2.2      | Il floor di 300 m è un vincolo debole . . . . .                             | 3         |
| 2.3      | Campionamento uniforme per distanza . . . . .                               | 4         |
| 2.4      | Visualizzazione: spawn maps . . . . .                                       | 4         |
| <b>3</b> | <b>FCM Adattivo vs. PPO Adattivo</b>                                        | <b>7</b>  |
| 3.1      | FCM Adattivo (Adam) . . . . .                                               | 7         |
| 3.2      | PPO Adattivo (catena a velocità variabile) . . . . .                        | 8         |
| 3.3      | Confronto quantitativo FCM-PPO . . . . .                                    | 13        |
| <b>4</b> | <b>Test di Modulazione: Raggio di Successo a 10 m</b>                       | <b>16</b> |
| 4.1      | Motivazione . . . . .                                                       | 16        |
| 4.2      | Setup . . . . .                                                             | 16        |
| 4.3      | Risultati . . . . .                                                         | 17        |
| <b>5</b> | <b>Formazione a Singola vs. Doppia Corona</b>                               | <b>19</b> |
| 5.1      | Motivazione e protocollo di confronto . . . . .                             | 19        |
| 5.2      | Architettura dell'osservazione . . . . .                                    | 21        |
| 5.3      | Risultati: confronto a ogni $v_{\max}$ . . . . .                            | 21        |
| 5.4      | Dove la doppia corona perde: analisi dei fallimenti differenziali . . . . . | 22        |
| 5.5      | Interpretazione . . . . .                                                   | 25        |
| 5.6      | Heatmap di occupazione dell'agente . . . . .                                | 25        |
| <b>6</b> | <b>Conclusioni</b>                                                          | <b>27</b> |

# 1 Introduzione

Questa relazione parte *in medias res*: non introduce il problema da zero, ma si innesta su risultati già ottenuti in precedenza. Il compito è il *source seeking* — un agente autonomo marino deve raggiungere la sorgente di un inquinante partendo da un punto interno al plume, guidato da sole misure locali di concentrazione, in un dominio marino 2D (baia di Cecina,  $3 \times 2,5$  km, risoluzione 10 m, passo temporale 10 s) con vento e correnti. Un episodio ha **successo** se l'agente entra entro un raggio dalla sorgente; le metriche sono il **success rate** (SR, frazione di episodi riusciti) e il numero di **step al successo** (rapidità).

I due termini di paragone **esistono già**, entrambi a **velocità costante**:

- **FCM puro** — il metodo del gradiente (*Field Climbing Method*), *training-free* e a passo fisso; nella configurazione migliore (sensor range 50 m) raggiunge un SR del **32,9%**;
- **PPO minimal** — una policy appresa con reinforcement learning a velocità fissa (1 m/s), molto più affidabile: **96,9%**.

Il divario di  $\sim 64$  punti percentuali tra i due quantifica quanto una policy appresa — con memoria dell'episodio e contesto idrodinamico — superi la pura risalita di gradiente locale.

Su questa base, la relazione introduce anzitutto una **nuova metrica di spawn**: i punti di partenza degli episodi sono distribuiti in modo *uniforme per distanza* in un disco  $[d_{\min}, d_{\max}]$  adattato alla diffusione del plume, in sostituzione della precedente distribuzione a intervallo fisso. Tutte le valutazioni che seguono sono prodotte con questa metrica. Studia poi il passaggio alla **velocità variabile**, confrontandone le due versioni — il FCM reso adattivo con Adam e la catena PPO a velocità crescente — con due approfondimenti: un test di **modulazione** della velocità (raggio di successo ridotto a 10 m) e l'aggiunta di una **seconda formazione di sensori** (doppia corona). La valutazione usa 26 sorgenti di test (SRC107–132) su quattro scenari di vento (V0–V3) e tre finestre temporali (Q1/4, Q1/2, Q3/4), descritti nel seguito.

## 2 Spawn Uniforme in $[d_{\min}, d_{\max}]$

### 2.1 Definizione del disco di spawn

Per ciascuno scenario (sorgente, vento, chunk temporale) il punto di spawn  $\mathbf{p}$  è scelto in modo da soddisfare un insieme di **vincoli** che definiscono un *disco ammissibile*  $[d_{\min}, d_{\max}]$  centrato sulla sorgente  $\mathbf{p}_s$ , dove  $d = \|\mathbf{p} - \mathbf{p}_s\|$  è la distanza dalla sorgente. Detto  $\{d_i\}$  l'insieme delle distanze delle celle di griglia appartenenti al plume, i vincoli sono:

- (V) validità:  $C(\mathbf{p}) \geq C_{\text{soglia}}, \text{dist}_{\text{terra}}(\mathbf{p}) \geq \ell_{\min}$
- (E) bordo esterno:  $d_{\max} = \min(d_{\text{cap}}, \max_i d_i)$
- (I) bordo interno:  $d_{\min} = \max(d_{\text{floor}}, P_{50}(\{d_i\}))$
- (W) ampiezza minima:  $d_{\max} - d_{\min} \geq w_{\min}$

con  $d_{\text{cap}} = 3000$  m,  $d_{\text{floor}} = 300$  m,  $w_{\text{min}} = 500$  m. All'interno del disco così definito, il punto di spawn viene **campionato** in tre passi:

- (U) distanza obiettivo:  $d^* \sim \mathcal{U}(d_{\text{min}}, d_{\text{max}})$
- (B) selezione cella:  $i^* \in \{i : |d_i - d^*| \leq \delta_b\}$
- (J) jitter:  $\mathbf{p} = \mathbf{c}_{i^*} + (\varepsilon_x, \varepsilon_y), \quad \varepsilon_x, \varepsilon_y \sim \mathcal{U}(-\delta_j, \delta_j)$

con  $\delta_b = 50$  m e  $\delta_j = 5$  m ( $\mathbf{c}_{i^*}$  è il centro della cella scelta). Ogni elemento ha un ruolo preciso:

- **(V) Validità** — lo spawn deve cadere su una cella *dentro il plume* (concentrazione sopra soglia  $C_{\text{soglia}}$ ) e a distanza di sicurezza dalla terraferma ( $\ell_{\text{min}}$ ). È il vincolo **forte**, non negoziabile: gli altri gli sono subordinati.
- **(E) Bordo esterno** — il raggio massimo è il minore tra un tetto assoluto  $d_{\text{cap}} = 3$  km e la cella di plume più lontana. Evita spawn oltre i 3 km anche quando il plume si estende di più.
- **(I) Bordo interno** — il raggio minimo è il maggiore tra un pavimento  $d_{\text{floor}} = 300$  m e la **mediana**  $P_{50}$  delle distanze del plume. Usare la mediana fa sì che  $d_{\text{min}}$  **scali con la diffusione**: plume esteso  $\Rightarrow$  mediana alta  $\Rightarrow d_{\text{min}}$  alta (spawn lontani); plume compatto  $\Rightarrow d_{\text{min}}$  bassa (spawn vicini). Il floor *tende a* evitare spawn nel raggio immediato della sorgente, ma è un vincolo *debole* (sottosezione successiva).
- **(W) Ampiezza minima** — l'intervallo deve essere largo almeno  $w_{\text{min}} = 500$  m; se risulta troppo stretto si abbassa  $d_{\text{min}}$  (fino al floor) per garantire una banda di spawn non degenerare. Nei casi limite di plume molto compatto, in cui nemmeno questo basta, scatta la clausola di sicurezza  $d_{\text{min}} = \min_i d_i$  (si campiona sull'estensione reale del plume; cfr. sottosezione successiva).
- **(U) Distanza obiettivo** — si estrae una distanza  $d^*$  *uniforme* in  $[d_{\text{min}}, d_{\text{max}}]$ . È questo passo a rendere il campionamento uniforme *per distanza* e non per area (chiarito in §2.3).
- **(B) Selezione della cella** — si sceglie a caso una cella valida del plume la cui distanza dalla sorgente differisce da  $d^*$  per meno di  $\delta_b = 50$  m (se nessuna rientra nella banda, si prende la più vicina a  $d^*$ ).
- **(J) Jitter** — alla posizione della cella si somma un piccolo rumore uniforme  $\pm\delta_j = \pm 5$  m su ciascuna coordinata, per non spawnare sempre esattamente al centro-cella.

## 2.2 Il floor di 300 m è un vincolo debole

Il vincolo **forte** è che lo spawn cada su una cella valida del plume; il floor  $d_{\text{floor}} = 300$  m è invece un *vincolo debole* e può essere violato. In pratica una frazione degli spawn risulta sotto i 300 m per due meccanismi distinti.

**(a) Tolleranza della banda di campionamento.** Anche con  $d_{\text{min}} = 300$  m, il campionamento accetta una cella entro  $|d_i - d^*| \leq 50$  m dal target (più jitter  $\pm 5$  m): con target prossimo a  $d_{\text{min}}$  vengono ammesse celle fino a  $\sim 250$  m. Sono gli spawn appena sotto soglia.

**(b) Fallback per plume compatto.** Il floor di 300 m presuppone che esistano celle di plume oltre tale distanza. Quando l'intero plume è più vicino (es. scenari poco diffusi in cui tutte le celle stanno entro  $\sim 200$  m), si ha  $d_{\max} = \max_i d_i < 300$  m e il floor non è onorabile; scatta allora la clausola di sicurezza  $d_{\min} = \min_i d_i$ , e si campiona sull'**estensione reale del plume**. In questi scenari uno spawn a 300 m semplicemente non esiste tra le celle valide.

### 2.3 Campionamento uniforme per distanza

Il passo (U) estrae la distanza obiettivo *uniformemente sulla distanza*, non sull'**area** del disco — ed è una scelta deliberata. Un campionamento uniforme nell'area concentrerebbe gli spawn sulla **corona esterna**: a distanza  $r$  la superficie disponibile cresce con  $r$  (una corona sottile ha area  $\approx 2\pi r dr$ ), quindi la maggior parte dei punti cadrebbe vicino al bordo esterno. Estruendo invece  $d^* \sim \mathcal{U}(d_{\min}, d_{\max})$  e scegliendo poi una cella a quella distanza (passo B), **ogni fascia di distanza è equiprobabile**, rendendo training e valutazione bilanciati rispetto alla distanza iniziale.

Sui dati di valutazione (1560 episodi), circa 260 spawn cadono sotto i 300 m: circa 100 nella fascia 250–300 m (tolleranza della banda, meccanismo *a*) e circa 160 sotto i 250 m (plume compatti, meccanismo *b*, fino a pochi metri). La copertura uniforme per distanza vale quindi entro l'*effettivo* intervallo  $[d_{\min}, d_{\max}]$  ammesso dalla geometria di ciascuno scenario.

### 2.4 Visualizzazione: spawn maps

Le *spawn maps* visualizzano, per le combinazioni vento/chunk con  $SR < 100\%$ , i punti di partenza colorati per esito (• successo, ✕ fallimento) su sfondo del plume, con le due circonferenze tratteggiate del disco  $[d_{\min}, d_{\max}]$  centrate sulla sorgente. Le distribuzioni mostrate dipendono **solo** dalla logica di spawn (non dal modello usato come coloratore): la copertura uniforme per distanza è evidente nella sezione di disco compresa tra le due circonferenze.

## Spawn map SRC114




Figura 1: Spawn map — SRC114 (coloratore PPO singola corona). Punti distribuiti uniformemente per distanza nel disco  $[d_{\min}, d_{\max}]$  (circonferenze tratteggiate, clippate al dominio).

## Spawn map SRC132




Figura 2: Spawn map — SRC132. La banda di spawn scala con la diffusione del plume di ciascuno scenario; successi e fallimenti non mostrano separazione spaziale sistematica.

### 3 FCM Adattivo vs. PPO Adattivo

Nel problema di *source seeking* l'agente deve raggiungere la sorgente di un inquinante partendo da un punto interno al plume, disponendo solo di misure locali di concentrazione. Un fattore decisivo per le prestazioni è la capacità di **modulare il passo**, cioè la distanza percorsa a ogni timestep. Un passo ampio fa avanzare rapidamente ma rischia di scavalcare la sorgente o di farsi trascinare dalla corrente; un passo breve è più preciso ma lento e vulnerabile ai timeout. Rispetto a un agente a passo fisso, un agente a **passo adattivo** può in principio accelerare quando è lontano e rallentare in prossimità della sorgente o in controcorrente.

Questo capitolo confronta due modi opposti di realizzare tale modulazione:

- **FCM adattivo (Adam)** — un metodo *training-free*: il passo è calcolato istante per istante da una regola deterministica applicata al gradiente di concentrazione stimato localmente. Non richiede addestramento e non possiede memoria oltre ai momenti del gradiente.
- **PPO adattivo** — una policy *appresa* con reinforcement learning: a ogni passo sceglie la coppia (direzione, velocità) massimizzando il ritorno atteso, sfruttando la storia delle osservazioni e le variabili di contesto (vento, corrente).

Il confronto è reso equo mettendo i due metodi **a parità di velocità massima**: a ciascun valore di  $lr$  del FCM corrisponde una velocità effettiva confrontabile con il  $v_{\max}$  di uno stadio della catena PPO. L'obiettivo è quantificare quanto un risalitore di gradiente, per quanto raffinato dal momentum, si avvicini a una policy che ha *imparato* a sfruttare memoria e contesto.

#### 3.1 FCM Adattivo (Adam)

Il *Field Climbing Method* (FCM) è un risalitore di gradiente: a ogni timestep stima la direzione di massima crescita della concentrazione e vi si muove. La versione classica usa un passo fisso e reagisce solo alla lettura corrente dei sensori, producendo traiettorie oscillanti quando il segnale è rumoroso. La variante *adattiva* sostituisce la regola di passo fisso con l'ottimizzatore **Adam**, che introduce una forma di memoria a breve termine sul gradiente.

**Stima del gradiente.** A ogni istante l'agente dispone di 8 sensori direzionali su una corona di raggio  $r_s = 50$  m. Da queste 8 letture ricostruisce il gradiente locale  $\hat{\nabla}C \in \mathbb{R}^2$  tramite regressione ai minimi quadrati (approssimazione di Taylor al primo ordine del campo di concentrazione attorno alla posizione corrente).

**Passo con Adam.** Il gradiente stimato non viene seguito direttamente, ma alimenta l'aggiornamento di Adam, che mantiene due medie mobili: il *momentum*  $\mathbf{m}$  (media del gradiente,  $\beta_1=0,9$ ) e la *varianza*  $\mathbf{v}$  (media del quadrato,  $\beta_2=0,999$ ). Il vettore di passo è  $\mathbf{s} = lr \cdot \hat{\mathbf{m}}/(\sqrt{\hat{\mathbf{v}}} + \varepsilon)$ . Ne derivano due effetti utili: il momentum **smorza le oscillazioni** da rumore del sensore mantenendo coerente la direzione su più timestep; la normalizzazione per  $\sqrt{\hat{\mathbf{v}}}$  **riduce il passo** nelle direzioni in cui il gradiente è incoerente nel tempo. La direzione discreta effettiva è quella degli 8 assi più allineata a  $\mathbf{s}$ , e il modulo del passo è cappato a  $\Delta x_{\max} = 50$  m.

**Significato di  $lr$ .** Il *learning rate* è il passo base in metri: a convergenza dei momenti, per gradienti cardinali si ha  $\|\mathbf{s}\| \rightarrow lr$ . Con  $\Delta t = 10$  s ciò equivale a una velocità

effettiva  $lr/\Delta t$  (es.  $lr=10\text{ m} \rightarrow 1\text{ m/s}$ ,  $lr=50\text{ m} \rightarrow 5\text{ m/s}$ ). I valori alti di  $lr$  superano la velocità nominale del veicolo ( $1\text{ m/s}$ ) e sono quindi poco realistici fisicamente: sono inclusi nello sweep solo per confrontabilità con la catena PPO a  $v_{\max}$  crescente. Lo sweep è condotto su 624 episodi per valore ( $26\text{ sorgenti} \times 4\text{ venti} \times 3\text{ chunk} \times 2\text{ ep}$ ), con la nuova metrica di spawn.

Le tabelle che seguono riportano il success rate anche disaggregato per **scenario di vento** e **finestra temporale**, gli stessi due assi usati in tutta la relazione: **V0–V3** sono le quattro condizioni di vento/corrente (V2 è la più avversa, corrente sostenuta); **Q1/4, Q1/2, Q3/4** sono tre istanti della simulazione (a 1/4, 1/2 e 3/4 della sua durata), che fissano lo stato del plume all’inizio dell’episodio.

| $lr$ (vel.)             | SR%         | Step (min)         | V0          | V1          | V2          | V3          | Q1/4        | Q1/2        | Q3/4        |
|-------------------------|-------------|--------------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|
| 10 m<br>(1 m/s)         | 54,6        | 174,0 (29,0)       | 73,7        | 29,5        | 35,9        | 79,5        | 77,9        | 30,3        | 55,8        |
| 20 m<br>(2 m/s)         | 58,2        | 131,5 (21,9)       | 80,1        | 32,1        | 34,6        | 85,9        | 81,7        | 38,0        | 54,8        |
| 30 m<br>(3 m/s)         | 60,7        | 110,4 (18,4)       | 84,6        | 30,8        | 37,2        | 90,4        | 86,1        | 39,4        | <b>56,7</b> |
| <b>40 m<br/>(4 m/s)</b> | <b>63,5</b> | 115,1 (19,2)       | <b>84,6</b> | <b>35,3</b> | <b>41,7</b> | 92,3        | <b>90,9</b> | <b>44,2</b> | 55,3        |
| 50 m<br>(5 m/s)         | 62,2        | <b>82,9 (13,8)</b> | 84,6        | 34,6        | 37,2        | <b>92,3</b> | 89,4        | 41,8        | 55,3        |

Tabella 1: FCM Adam — sweep su  $lr$  (624 episodi per valore,  $r_s=50\text{ m}$ ,  $\Delta x_{\max}=50\text{ m}$ ). “Step (min)” riporta gli step medi al successo e, tra parentesi, i minuti corrispondenti (1 step = 10 s). In verde il valore ottimale  $lr=40\text{ m}$  (SR globale 63,5%); in grassetto il migliore per colonna.

All’aumentare di  $lr$  crescono sia il success rate (fino a  $lr=40\text{ m}$ , 63,5%) sia la velocità: gli step medi al successo scendono da 174 a 83. Oltre  $lr=40\text{ m}$  il passo diventa così lungo da **scavalcare** talvolta la sorgente, e l’SR cala leggermente ( $lr=50\text{ m}$ : più veloce ma 62,2%). Il limite strutturale del metodo emerge dal profilo per scenario: negli ambienti a plume avvertato (V1, V2) l’SR resta fermo al 30–42%. La ragione è che lì il gradiente *locale* punta lungo la corrente e non verso la sorgente: nessun momentum locale può supplire all’assenza di memoria globale dell’episodio e di informazione sul contesto idrodinamico. Il FCM Adam, pur guadagnando molto sul FCM puro, satura quindi intorno al 63%.

### 3.2 PPO Adattivo (catena a velocità variabile)

**Spazio d’azione.** Per rendere la velocità una scelta dell’agente, lo spazio d’azione passa da 8 direzioni (passo fisso) a Discrete( $8 \times K$ ) con  $K = 5$ : ogni azione codifica *congiuntamente* una delle 8 direzioni e uno dei 5 livelli di velocità  $\{0,2, 0,4, \dots, 1,0\} \cdot v_{\max}$ . L’agente sceglie così a ogni passo non solo *dove* andare ma anche *quanto* spingere. La velocità ottimale non è imposta da una regola: emerge **implicitamente** dall’ottimizzazione del ritorno — l’agente potrebbe apprendere, ad esempio, che rallentare in prossimità della sorgente o in controcorrente conviene.

**Perché una catena di warm-start.** Passare direttamente da un modello a passo fisso (1 m/s) a uno con velocità libera fino a 5 m/s è un salto difficile: lo spazio d'azione si quintuplica (da 8 a 40 azioni) e la dinamica dell'episodio cambia. L'addestramento è perciò organizzato a **catena**, in modo che ogni incremento sia un piccolo aggiustamento su una policy già competente anziché un apprendimento da zero:

- il primo stadio ( $v_{\max}=1$ ) parte dal modello *minimal* a passo fisso, ne **trapianta il corpo** (le rappresentazioni già apprese) ed espande la testa d'azione da 8 a 40 uscite; l'agente impara a modulare la velocità entro lo stesso tetto di 1 m/s;
- ogni stadio successivo ( $v_{\max}=2, \dots, 5$ ) riparte dal precedente (fine-tuning) e alza progressivamente il tetto di velocità.

Ogni stadio è valutato su 1560 episodi.




Figura 3: Warm-start del primo stadio (*minimal*  $\rightarrow$  v1). Il **corpo** della rete (ingresso a 116 dim. e MLP  $256 \times 256$ ) viene **copiato** invariato (verde); solo la **testa d'azione** viene **espansa** da 8 a 40 uscite (arancio): ogni direzione viene replicata sui 5 livelli di velocità, con bias iniziale verso  $v_{\max}$  (all'avvio la policy equivale a quella a passo fisso).




Figura 4: Focus sulla testa d'azione (espansione  $8 \rightarrow 40$ ). Ciascuna delle 8 direzioni della testa *minimal* viene sdoppiata nei 5 livelli di velocità ( $d_i, v_k$ ): i pesi sono replicati e il livello  $v_{\max}$  è favorito all'avvio, così la policy parte equivalente a quella a passo fisso.

| $v_{\max}$   | SR%         | Step (min)        | V0    | V1    | V2          | V3    | Q1/4  | Q1/2  | Q3/4  |
|--------------|-------------|-------------------|-------|-------|-------------|-------|-------|-------|-------|
| 1 m/s        | 97,1        | 119,6 (19,9)      | 99,5  | 100,0 | 89,7        | 99,2  | 100,0 | 95,0  | 96,3  |
| 2 m/s        | 99,7        | 69,5 (11,6)       | 100,0 | 99,5  | 99,2        | 100,0 | 100,0 | 99,0  | 100,0 |
| 3 m/s        | 99,9        | 46,9 (7,8)        | 100,0 | 100,0 | 99,7        | 100,0 | 100,0 | 99,8  | 100,0 |
| 4 m/s        | 99,9        | 38,2 (6,4)        | 100,0 | 100,0 | 99,5        | 100,0 | 100,0 | 100,0 | 99,6  |
| <b>5 m/s</b> | <b>99,9</b> | <b>27,8 (4,6)</b> | 100,0 | 100,0 | <b>99,7</b> | 100,0 | 100,0 | 100,0 | 99,8  |

Tabella 2: Catena PPO a velocità variabile (1560 episodi per stadio,  $K=5$ ). “Step (min)” riporta gli step medi al successo e, tra parentesi, i minuti corrispondenti (1 step = 10 s). All’aumentare di  $v_{\max}$  crescono SR e velocità (step medi da  $\sim 20$  a  $\sim 5$  min).

Già il primo stadio ( $v_{\max}=1$ , equivalente in velocità al modello a passo fisso) raggiunge il 97,1%. Alzare  $v_{\max}$  produce due benefici congiunti: l’SR sale al 99,7–99,9% e gli step medi al successo crollano da 120 a 28 ( $\sim 5\times$  più veloce). Il guadagno maggiore è su **V2**, lo scenario a corrente forte: la velocità netta dell’agente è  $v_{\text{agente}} - v_{\text{corrente}}$ , e con più velocità disponibile l’agente batte più facilmente la corrente contraria, passando da 89,7% a 99,7%. A partire da  $v_{\max}=3$  le prestazioni sono sostanzialmente sature ( $\approx 99,9\%$ ): l’ulteriore margine di velocità serve solo a ridurre il tempo al successo, non l’affidabilità.

### Andamento della velocità media

Per ciascuno stadio della catena si riporta la velocità media (su tutte le run) nel tempo. In media l’agente resta prossimo a  $v_{\max}$  a ogni stadio; la modulazione (gli avvallamenti della media e l’ampiezza della banda) **non è monotona** in  $v_{\max}$ : è **massima agli stadi intermedi** ( $v_{\max}=2,3$ ) e **quasi assente agli estremi**. A  $v_{\max}=1$  il passo pieno (10 m) è molto minore del raggio di successo (50 m): non c’è rischio di scavalcare la sorgente, andare al massimo è quasi sempre sicuro e la media resta piatta. A  $v_{\max}=5$  il passo pieno (50 m) eguaglia il raggio e, grazie alla cattura sul segmento percorso, una falcata piena centra comunque il bersaglio: di nuovo conviene il massimo. Ai valori intermedi, invece, il passo diventa confrontabile con la scala di avvicinamento e i rallentamenti correttivi si fanno più evidenti.




(a)  $v_{\max}=1$  m/s(b)  $v_{\max}=2$  m/s(c)  $v_{\max}=3$  m/s

Figura 5: PPO adattivo: velocità media (su tutte le run) nel tempo, stadi  $v_{\max}=1,2,3$  (continua nella figura successiva). In media l'agente resta prossimo a  $v_{\max}$  ma modula il passo con rallentamenti correttivi, più evidenti agli stadi intermedi ( $v_{\max}=2,3$ ) e quasi assenti agli estremi ( $v_{\max}=1$  e 5).



(a)  $v_{\max}=4$  m/s(b)  $v_{\max}=5$  m/s

Figura 6: PPO adattivo: velocità media nel tempo, stadi  $v_{\max}=4,5$  (segue dalla figura precedente).





### 3.3 Confronto quantitativo FCM–PPO





| Vel. / metodo        | SR%   | V0    | V1    | V2    | V3    | Q1/4  | Q1/2  | Q3/4  |
|----------------------|-------|-------|-------|-------|-------|-------|-------|-------|
| FCM ( $lr=10$ )      | 54,6  | 73,7  | 29,5  | 35,9  | 79,5  | 77,9  | 30,3  | 55,8  |
| PPO ( $v_{\max}=1$ ) | 97,1  | 99,5  | 100,0 | 89,7  | 99,2  | 100,0 | 95,0  | 96,3  |
|                      | +42,5 | +25,8 | +70,5 | +53,8 | +19,7 | +22,1 | +64,7 | +40,6 |
| FCM ( $lr=20$ )      | 58,2  | 80,1  | 32,1  | 34,6  | 85,9  | 81,7  | 38,0  | 54,8  |
| PPO ( $v_{\max}=2$ ) | 99,7  | 100,0 | 99,5  | 99,2  | 100,0 | 100,0 | 99,0  | 100,0 |
|                      | +41,5 | +19,9 | +67,4 | +64,6 | +14,1 | +18,3 | +61,1 | +45,2 |
| FCM ( $lr=30$ )      | 60,7  | 84,6  | 30,8  | 37,2  | 90,4  | 86,1  | 39,4  | 56,7  |
| PPO ( $v_{\max}=3$ ) | 99,9  | 100,0 | 100,0 | 99,7  | 100,0 | 100,0 | 99,8  | 100,0 |
|                      | +39,2 | +15,4 | +69,2 | +62,6 | +9,6  | +13,9 | +60,4 | +43,3 |
| FCM ( $lr=40$ )      | 63,5  | 84,6  | 35,3  | 41,7  | 92,3  | 90,9  | 44,2  | 55,3  |
| PPO ( $v_{\max}=4$ ) | 99,9  | 100,0 | 100,0 | 99,5  | 100,0 | 100,0 | 100,0 | 99,6  |
|                      | +36,4 | +15,4 | +64,7 | +57,8 | +7,7  | +9,1  | +55,8 | +44,3 |
| FCM ( $lr=50$ )      | 62,2  | 84,6  | 34,6  | 37,2  | 92,3  | 89,4  | 41,8  | 55,3  |
| PPO ( $v_{\max}=5$ ) | 99,9  | 100,0 | 100,0 | 99,7  | 100,0 | 100,0 | 100,0 | 99,8  |
|                      | +37,8 | +15,4 | +65,4 | +62,6 | +7,7  | +10,6 | +58,2 | +44,5 |

Tabella 3: FCM adattivo vs. PPO adattivo a parità di velocità massima (FCM:  $lr/\Delta t$ ; PPO:  $v_{\max}$ ), per scenario di vento (V) e chunk temporale (Q). Sotto ogni valore PPO, in verde, il **surplus** sul FCM (punti percentuali). Il PPO domina a ogni livello di velocità e su ogni scenario.

A parità di velocità il PPO supera il FCM di un margine ampio e sistematico (+36–42 punti di SR globale). Il divario è **massimo** proprio negli scenari più avversi (V1, V2): lì la risalita di gradiente *locale* viene ingannata dal plume avvertato, mentre la policy appresa sfrutta memoria dell’episodio e contesto idrodinamico per non perdere la sorgente.

Il confronto per scenario (vento V, chunk Q) è riportato **a parità di velocità** per ogni livello: in ciascuna figura il FCM (in alto) e il PPO (in basso) alla stessa velocità massima.

(a) FCM Adam ( $lr=10$  m).(b) PPO adattivo ( $v_{\max}=1$ ).Figura 7: Success rate per scenario — **velocità 1 m/s** (FCM sopra, PPO sotto).(a) FCM Adam ( $lr=20$  m).(b) PPO adattivo ( $v_{\max}=2$ ).Figura 8: Success rate per scenario — **velocità 2 m/s** (FCM sopra, PPO sotto).

(a) FCM Adam ( $lr=30$  m).(b) PPO adattivo ( $v_{max}=3$ ).Figura 9: Success rate per scenario — **velocità 3 m/s** (FCM sopra, PPO sotto).(a) FCM Adam ( $lr=40$  m, *best*).(b) PPO adattivo ( $v_{max}=4$ ).Figura 10: Success rate per scenario — **velocità 4 m/s** (FCM sopra, PPO sotto).



(a) FCM Adam ( $lr=50$  m).(b) PPO adattivo ( $v_{\max}=5$ ).

Figura 11: Success rate per scenario — velocità 5 m/s (FCM sopra, PPO sotto).

## 4 Test di Modulazione: Raggio di Successo a 10 m

### 4.1 Motivazione

I risultati della catena a velocità variabile mostrano che, in media, l'agente resta prossimo a  $v_{\max}$ . Sorge quindi una domanda: l'agente *sa* davvero rallentare, o gli conviene sempre andare al massimo? Con un raggio di successo di 50 m la domanda è mal posta: il raggio (50 m) è grande quanto un passo pieno (50 m a  $v_{\max}=5$ ), quindi l'agente può **piombare** sulla sorgente a piena velocità e centrare comunque la palla dei 50 m, senza alcun bisogno di rallentare.

Per rendere il compito più stringente si **restringe il raggio di successo a 10 m**. Ora un passo pieno da 50 m **scavalca** un bersaglio da 10 m, e centrare un target così stretto non è più banale. La domanda è allora: per riuscirci l'agente impara a *rallentare* in avvicinamento, oppure adotta un'altra strategia? In entrambi i casi il prezzo atteso è un maggior numero di step.

### 4.2 Setup

Il modello (ppo\_20260630\_090846) è ottenuto per fine-tuning a partire dallo stadio  $v_{\max}=5$ , cambiando solo il raggio di successo (50  $\rightarrow$  10 m), con soglia di stagnazione ridotta,  $lr = 10^{-4}$ , curriculum  $\alpha = 0,8$ , per 2 M timestep. La valutazione è su 1560 episodi, identica agli altri stadi.


### 4.3 Risultati

| Raggio              | SR%          | Step (min)          | V0           | V1           | V2           | V3           | Q1/4         | Q1/2         | Q3/4         |
|---------------------|--------------|---------------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|
| $v_{\max}=5$ , 50 m | 99,9         | 27,8 (4,6)          | 100,0        | 100,0        | 99,7         | 100,0        | 100,0        | 100,0        | 99,8         |
| $v_{\max}=5$ , 10 m | 99,2<br>-0,7 | 54,8 (9,1)<br>+27,0 | 100,0<br>0,0 | 98,5<br>-1,5 | 98,5<br>-1,2 | 100,0<br>0,0 | 98,7<br>-1,3 | 99,4<br>-0,6 | 99,6<br>-0,2 |


Tabella 4: Effetto del restringimento del raggio di successo ( $50 \rightarrow 10$  m) sullo stadio  $v_{\max}=5$  (1560 episodi). Sotto ogni valore a 10 m, il delta rispetto alla configurazione a 50 m (in rosso i cali di SR; in grigio l'aumento — atteso — degli step). Il success rate resta sostanzialmente invariato ( $-0,7$ ), ma gli step medi al successo **raddoppiano** (da  $\sim 5$  a  $\sim 9$  min).

Con un bersaglio cinque volte più piccolo l'agente continua a raggiungerlo quasi sempre (99,2%), ma **impiega circa il doppio degli step** ( $27,8 \rightarrow 54,8$ , ovvero  $4,6 \rightarrow 9,1$  min). Il dato interessante è *dove* va a finire questo tempo extra: **non** in un rallentamento. La velocità media resta infatti prossima al massimo (4,98 m/s), praticamente identica alla configurazione a 50 m.

Il motivo è nel criterio di cattura: il successo è valutato sul **segmento percorso** (posizione precedente  $\rightarrow$  corrente), non solo sull'endpoint. Un passo pieno da 50 m la cui traiettoria passa entro 10 m dalla sorgente conta già come successo; l'agente quindi **non è obbligato a frenare** — gli basta indirizzare una falcata che sfiori il bersaglio. Centrare un target da 10 m con passi da 50 m richiede però più manovre: l'agente **scavalca e ri-approccia** ripetutamente attorno alla sorgente (Fig. 13), accumulando step a velocità quasi piena. Il costo del bersaglio più piccolo si paga quindi in **lunghezza del percorso**, non in velocità: il test mostra che la policy sa *manovrare* finemente attorno a un target stretto, più di quanto mostri un rallentamento sistematico.




(a) Velocità media in funzione della distanza dalla sorgente (asse invertito: lontano a sinistra, vicino a destra; linea rossa = raggio di successo).




(b) Velocità media nel tempo.

Figura 12: Esperimento a raggio 10 m: la velocità media resta **prossima al massimo** a ogni distanza dalla sorgente (a). L'apparente trend discendente nel tempo (b) è soprattutto un effetto di *selezione*: a tempi lunghi sopravvivono solo le run difficili (V2 in controcorrente), che viaggiano più lente; non è un rallentamento sistematico in avvicinamento.



(a) Cattura “pulita” con un singolo giro attorno alla sorgente (35 step).



(b) Manovra intensa: scavalcamenti e ri-approcci ripetuti (139 step).

Figura 13: Traiettorie di inferenza r10 (scenari V2, esiti di successo): l’agente scende lungo il plume a piena velocità e poi **manovra / scavalca ripetutamente** attorno alla sorgente per far passare una falcata entro i 10 m. Il costo è un percorso più lungo (più step), non una velocità più bassa.

## 5 Formazione a Singola vs. Doppia Corona

### 5.1 Motivazione e protocollo di confronto

La doppia corona aggiunge alla corona locale di 8 sensori a  $r_s = 20$  m una **seconda corona** a  $r_{s2} = 50$  m, per dare all’agente informazione sul plume a scala spaziale più

larga. La domanda è: questa seconda corona **serve**, e **a quali velocità**?

Nel report precedente il modello a doppia corona era addestrato *da zero* e mostrava un calo di SR di  $-3,9$  punti: quel calo però **confondeva** l'effetto del sensore con la maggiore difficoltà di ottimizzare da zero una rete più grande.

Per un confronto **equo** e **a ogni livello di velocità**, la doppia corona è ottenuta per **warm-start dal corrispondente modello a singola corona**: per ogni  $v_{\max} \in \{1, \dots, 5\}$ , il modello `dualcorona_vX` parte da `vmax_X` (stessa velocità), espandendo lo strato di ingresso da 116 a 196 dimensioni e **azzerando** le colonne della corona-2. All'avvio la rete è quindi *identica* alla singola corona (ignora la corona-2) e impara durante il fine-tuning se e come usarla: ogni eventuale differenza è così attribuibile al solo sensore, non al protocollo. Ogni modello è valutato su 1560 episodi; la figura seguente illustra il warm-start (esempio a  $v_{\max}=1$ ).




Figura 14: Warm-start della doppia corona (esempio a  $v_{\max}=1$ :  $v1 \rightarrow$  doppia corona; a ogni livello è analogo, dal rispettivo `vmax_X`). **Corpo** e **testa d'azione** sono **copiati** invariati (verde); si allarga solo lo **strato d'ingresso** da 116 a 196 (arancio), aggiungendo 80 colonne per la corona-2 con **pesi inizializzati a zero**. All'avvio la rete è identica a  $v1$  e ignora la corona-2; il fine-tuning decide se e come usarla.




Figura 15: Focus sull'allargamento dello strato d'ingresso ( $116 \rightarrow 196$ ). La matrice del primo layer guadagna 80 colonne (una per sensore della corona-2), **inizializzate a zero**: all'avvio la corona-2 non influenza le unità nascoste e la rete si comporta esattamente come  $v1$ .

## 5.2 Architettura dell'osservazione

| Componente                      | Singola    | Doppia     |
|---------------------------------|------------|------------|
| Concentrazione corrente         | 1          | 1          |
| Memoria concentrazione (9 step) | 9          | 9          |
| Memoria spostamenti (9 step)    | 18         | 18         |
| Sensori corona 1 (8 dir.)       | 8          | 8          |
| Sensori corona 2 (8 dir.)       | –          | 8          |
| Memoria storica corona 1 (9×8)  | 72         | 72         |
| Memoria storica corona 2 (9×8)  | –          | 72         |
| Vento (2D) + Corrente (2D)      | 4          | 4          |
| Informazione posizionale        | 4          | 4          |
| <b>Totale</b>                   | <b>116</b> | <b>196</b> |

Tabella 5: Spazio di osservazione: singola (116) vs. doppia corona (196).

## 5.3 Risultati: confronto a ogni $v_{\max}$

Il risultato principale è il confronto complessivo, singola vs. doppia corona a ciascun livello di velocità (1560 episodi per cella).

| $v_{\max}$ | SR<br>sing. | SR<br>dopp. | Step sing.          | Step dopp.      | $\Delta\text{step}$ |
|------------|-------------|-------------|---------------------|-----------------|---------------------|
| 1          | 97,1%       | 95,8%       | 119,6<br>(19,9 min) | 97,8 (16,3 min) | –18,2%              |
| 2          | 99,7%       | 99,7%       | 69,5 (11,6 min)     | 49,8 (8,3 min)  | –28,3%              |
| 3          | 99,9%       | 100,0%      | 46,9 (7,8 min)      | 31,3 (5,2 min)  | –33,2%              |
| 4          | 99,9%       | 99,9%       | 38,2 (6,4 min)      | 25,3 (4,2 min)  | –33,6%              |
| 5          | 99,9%       | 100,0%      | 27,8 (4,6 min)      | 20,9 (3,5 min)  | –24,8%              |

Tabella 6: Singola vs. doppia corona a ogni  $v_{\max}$  (ogni doppia corona warm-startata dal singola-corona omologo; 1560 episodi per cella). “Step” = step medi al successo (minuti tra parentesi).  $\Delta\text{step}$  = variazione relativa dei passi (verde = doppia più veloce).

Se ne leggono due fatti, che **ribaltano** la lettura del report precedente (basata sul solo  $v_{\max}=1$ , dove la seconda corona sembrava “scambiare robustezza per velocità senza migliorare l’SR”):

- **Il costo di SR è confinato a  $v_{\max}=1$ :** la penalità  $-1,3$  non si ripresenta ai livelli superiori — a  $v_2$ – $v_5$  l’SR della doppia corona è *pari o superiore* a quello della singola (99,7–100% vs 99,7–99,9%).

- **Il guadagno di step non si assottiglia: cresce.** Da  $-18\%$  (v1) sale a un picco di  $\sim -34\%$  (v3-v4), per poi ridursi a  $-25\%$  (v5, per effetto pavimento: la singola è già a  $\sim 28$  step, vicino al minimo geometrico).

Il motivo è che il valore della “vista lontana” (corona a 50 m) **scala con la lunghezza del passo**: a  $v_{\max}$  alto le falcate sono grandi (fino a 50 m) e una falcata mal puntata costa un *overshoot* con relative correzioni; la corona-2, vedendo a 50 m, punta meglio le falcate lunghe ed evita proprio quelle correzioni che rallentano la singola. La conseguenza pratica: **dalle velocità intermedie in su la doppia corona è un vantaggio netto** — stessa affidabilità e 25–34% di passi in meno. Resta da capire *solo* il livello base,  $v_{\max}=1$ , l’unico in cui la doppia corona costa qualcosa.

### Sguardo ravvicinato a $v_{\max}=1$

A  $v_{\max}=1$  il dettaglio per scenario (vento V e chunk Q):

| Metrica           | Singola (116)            | Doppia (196)                             |
|-------------------|--------------------------|------------------------------------------|
| SR globale        | <b>97,1%</b>             | 95,8% <span>(-1,3)</span>                |
| Step medi (succ.) | 119,6 ( $\sim 19,9$ min) | <b>97,8 (<math>\sim 16,3</math> min)</b> |
| V0                | <b>99,5%</b>             | 99,7% <span>(+0,2)</span>                |
| V1                | <b>100,0%</b>            | 98,7% <span>(-1,3)</span>                |
| V2                | <b>89,7%</b>             | 86,2% <span>(-3,5)</span>                |
| V3                | <b>99,2%</b>             | 98,7% <span>(-0,5)</span>                |
| Q1/4              | 100,0%                   | 100,0% 0,0                               |
| Q1/2              | 95,0%                    | <b>97,1%</b> <span>(+2,1)</span>         |
| Q3/4              | <b>96,3%</b>             | 90,4% <span>(-5,9)</span>                |

Tabella 7:  $v_{\max}=1$ : singola (vmax\_1) vs. doppia corona warm-start (dualcorona\_v1), 1560 episodi ciascuno.

Con il warm-start il divario di SR si **riduce** da  $-3,9$  (da zero) a  $-1,3$ , confermando che parte della penalità originale era difficoltà di ottimizzazione, non informazione dannosa. Il residuo  $-1,3$  è concentrato in **V2** ( $89,7 \rightarrow 86,2$ ) e **Q3/4** ( $96,3 \rightarrow 90,4$ ); la prossima sezione ne isola l’origine.

## 5.4 Dove la doppia corona perde: analisi dei fallimenti differenziali


Restando su  $v_{\max}=1$  — l’unico livello con un costo di SR — appaiando i 1560 episodi per (sorgente, vento, chunk, episodio) si isolano i casi in cui **la singola riesce e la doppia fallisce**:

| Esito appaiato                     | N. episodi           |
|------------------------------------|----------------------|
| Entrambi successo                  | 1463                 |
| Entrambi fallimento                | 13                   |
| Singola OK, <b>doppia FALLISCE</b> | <b>52</b>            |
| Singola fallisce, doppia OK        | 32                   |
| <b>Netto</b>                       | <b>-20 (= -1,3%)</b> |


Tabella 8: Matrice degli esiti appaiati singola vs. doppia corona.

I 52 fallimenti differenziali hanno una firma nettissima:

- sono **tutti timeout** (nessuna uscita dal dominio);
- **81% su vento V2** (42/52), nei chunk a corrente sostenuta (Q3/4, Q1/2);
- su **spawn lontani**: distanza iniziale media 1070 m contro 690 m della media generale;
- **non sono near-miss**: 36/52 non scendono mai sotto 150 m dalla sorgente (distanza minima mediana 322 m) — l'agente **si perde**, non “non riesce a frenare”.



(a) SR per distanza iniziale (V2).



(b) Distanza minima raggiunta sui 52 fallimenti.

Figura 16: Sopra: in V2 la doppia corona è pari/migliore sugli spawn vicini e crolla su quelli lontani. Sotto: i fallimenti differenziali sono “persi” (mai sotto 150 m), non avvicinamenti stallati.

Il crollo è tutto nel regime “lontano + corrente forte”: in V2 la SR per fascia di distanza iniziale passa da +1,1 (300–700 m, doppia leggermente migliore) a −15,2 (1100–1600 m) fino a −83,3 (oltre 1600 m).

### Il caso opposto: dove la doppia corona vince

Per completezza vanno analizzati anche i **32 casi in cui la singola fallisce e la doppia riesce**. Anch’essi sono **tutti timeout** della singola e **concentrati in V2** (28/32), ma con una firma *complementare* rispetto ai 52 fallimenti:

- il chunk dominante è **Q1/2** (25/32), non Q3/4;
- gli spawn sono a distanza **moderata** (media 749 m, contro i 1070 m dei casi in cui la doppia perde);

- la singola vi fallisce in modo misto — 11/32 near-miss (arriva  $< 70$  m e stalla) e 14/32 “persa” — mentre la doppia li recupera, ma **a caro prezzo**: 258 step medi ( $\sim 43$  min).

Ne emerge che la doppia corona **non è uniformemente peggiore: redistribuisce** i successi lungo l’asse temporale. Sui chunk **Q1/2** (spawn a distanza moderata) il segnale a 50 m aiuta a tenere la rotta ed è in **attivo** (25 recuperi contro 14 perdite); sui chunk **Q3/4** (spawn più lontani, corrente più sostenuta) lo stesso segnale inganna ed è in **passivo** (7 recuperi contro 38 perdite). Il bilancio complessivo è  $-20$ : uno **spostamento** della frontiera di successo, non una regressione generalizzata.

## 5.5 Interpretazione

Il filo che tiene insieme tutti i risultati è uno solo: la corona-2 sente il campo **più lontano** (50 m), e il valore di questa “vista lontana” dipende da *quanto lontano l’agente sta per muoversi*, cioè dalla lunghezza del passo.

**Perché il vantaggio di velocità cresce con  $v_{\max}$ .** A  $v_{\max}$  alto le falcate sono grandi (fino a 50 m): una falcata mal puntata scavalca la rotta e costa correzioni. La corona-2, vedendo a 50 m, è esattamente “un passo avanti” e permette di puntare bene le falcate lunghe, evitando gli *overshoot* che rallentano la singola. A  $v_{\max}$  basso il passo è piccolo (20 m): il segnale lontano è meno decisivo, e infatti il guadagno è minore ( $-18\%$  a  $v1$  contro  $\sim -34\%$  a  $v3-v4$ ). Il leggero calo a  $v5$  è effetto pavimento: la singola è già vicina al minimo di step.

**Perché il costo di affidabilità esiste solo a  $v_{\max}=1$ .** A passi piccoli l’agente resta più a lungo immerso nel campo, e in **V2** (corrente forte, plume fortemente avvettato) il segnale a 50 m può puntare *lungo la corrente* anziché verso la sorgente: sugli spawn lontani l’agente si fida del segnale distante, prende la direzione sbagliata e va in timeout. È lo stesso meccanismo che dà velocità, ribaltato nel regime “lontano + corrente forte” — ma solo a  $v1$ , dove i passi piccoli lasciano tempo di perdersi. Alle velocità superiori l’agente attraversa quel regime troppo in fretta perché l’errore si accumuli, e il costo sparisce.

**Perché l’agente non ignora la corona-2.** “Ignorare” equivale a pesi d’ingresso esattamente nulli, una soluzione che la discesa del gradiente non raggiunge (anche partendo da zero come nel warm-start, i gradienti spostano quei pesi). Soprattutto, **usarla aumenta il reward**: lo `step_penalty` premia l’arrivare prima, e la corona-2 dà traiettorie più dirette; l’ottimizzatore quindi *sceglie* di usarla.

**In sintesi.** La seconda corona è un **vantaggio netto** a partire da  $v_{\max}=2$ : stessa affidabilità e 25–34% di passi in meno. Solo a  $v_{\max}=1$  si osserva un piccolo scambio robustezza/velocità ( $-1,3$  di SR per  $-18\%$  di step), confinato agli spawn lontani in corrente forte. La lettura del report precedente — “la doppia corona non migliora l’SR, scambia robustezza per velocità” — era un artefatto dell’aver guardato *solo*  $v_{\max}=1$ .

## 5.6 Heatmap di occupazione dell’agente

Per un riscontro *visivo* dei risultati numerici si riportano alcune **heatmap di occupazione**: dato uno scenario (sorgente, vento, chunk) si eseguono 10 episodi e si accumula la **densità di presenza** dell’agente sul dominio (stile “heatmap sportive”), su sfondo geografico (mare, costa, sorgente  $\star$ ). Si confrontano tre agenti alla **stessa velocità**

**massima: FCM** (5 m/s), **PPO singola corona** ( $v_{\max}=5$ ) e **PPO doppia corona** ( $v_{\max}=5$ ), su 5 scenari *difficili* (vento V1/V2, chunk Q1/2 o Q3/4). La scala colori è **comune ai tre pannelli**, fissata sui due modelli PPO (confrontabili); l'FCM, che oscilla a lungo negli stessi punti, ha densità di picco molto più alte e quindi **satura**.

### Considerazioni.

- **FCM vs. PPO.** L'FCM resta **intrappolato** in macchie oscillanti lontane dalla sorgente e quasi sempre fallisce (0–5/10), mentre il PPO forma una scia che **converge sulla sorgente** (10/10). È la controparte visiva del divario di SR (+36–42 punti): la risalita di gradiente *locale*, senza memoria né contesto, si perde nel plume avvevato.
- **Singola vs. doppia corona.** Entrambe raggiungono la sorgente, ma la **doppia corona concentra la presenza in un corridoio più stretto e definito** (più luminoso a parità di scala), mentre la singola è più dispersa. È la controparte visiva del –34% di step: la seconda corona rende la rotta più diretta e ripetibile.
- **Come si legge.** La luminosità indica la *densità di passaggio*, non la velocità: un tratto più luminoso vicino alla sorgente riflette la **convergenza** di tutte le run in un corridoio comune, non un rallentamento (la velocità resta  $\sim v_{\max}$ ).




Figura 17: Heatmap di occupazione — SRC114, V2, Q3/4. FCM (sinistra) vs. PPO singola (centro) vs. PPO doppia corona (destra),  $v_{\max}=5$ , scala comune.




Figura 18: Heatmap di occupazione — SRC120, V2, Q1/2.




Figura 19: Heatmap di occupazione — SRC117, V2, Q3/4.




Figura 20: Heatmap di occupazione — SRC109, V1, Q3/4.




Figura 21: Heatmap di occupazione — SRC130, V2, Q1/2.

## 6 Conclusioni

In questa relazione abbiamo confrontato un metodo del gradiente (FCM) e una policy appresa con PPO per la localizzazione di sorgenti inquinanti marine con agenti a **passo adattivo**, lungo quattro assi.

1. **Spawn uniforme** in  $[d_{\min}, d_{\max}]$ . La nuova metrica distribuisce i punti di partenza *uniformemente per distanza* in un disco adattato alla diffusione del plume

(bordo interno = mediana delle distanze del plume, con floor 300 m; bordo esterno  $\leq 3$  km). Le spawn maps confermano che successi e fallimenti **non** hanno separazione spaziale: l'esito dipende dalle condizioni idrodinamiche locali, non dalla geometria dello spawn.

2. **FCM adattivo vs. PPO adattivo.** A parità di velocità massima il PPO **domina** il FCM di +36–42 punti di SR. Il momentum di Adam porta il FCM dal 32,9% (passo fisso) al  $\sim 63\%$ , ma lì satura: la risalita di gradiente *locale* non sostituisce la memoria globale dell'episodio e il contesto idrodinamico che la policy appresa sfrutta — soprattutto negli scenari avversi (V1, V2), dove il gradiente locale viene ingannato dal plume avvettato.
3. **Modulazione della velocità (raggio 10 m).** Restrungendo il raggio di successo da 50 a 10 m l'agente continua a riuscire (99,2%) ma raddoppia gli step. Il tempo extra **non** viene da un rallentamento (velocità media invariata,  $\sim 4,98$  m/s): con la cattura sul segmento percorso all'agente basta *sfiore* il bersaglio, quindi non frena ma **manovra** con un percorso più lungo.
4. **Singola vs. doppia corona.** Con un confronto equo a *ogni*  $v_{\max}$  (warm-start della doppia corona dal singola-corona omologo), la seconda corona è un **vantaggio netto** da  $v_{\max} \geq 2$ : stessa affidabilità (99,7–100%) e 25–34% di passi in meno. Il costo di SR (−1,3) esiste **solo** a  $v_{\max}=1$ , sugli spawn lontani in corrente forte (V2). Il vantaggio cresce con la velocità perché la “vista lontana” (50 m) vale di più quando le falcate sono grandi.

**Sintesi.** L'agente appreso con PPO supera nettamente il metodo del gradiente, e la capacità di **modulare la velocità** unita a una **seconda formazione di sensori** rende la ricerca più rapida senza sacrificare l'affidabilità. Il valore della seconda corona, in particolare, si apprezza solo valutandola su **tutto** l'intervallo di velocità: a  $v_{\max}=1$  sembrerebbe dannosa, mentre da  $v_{\max} \geq 2$  è un vantaggio netto (stessa affidabilità, fino a −34% di step).